



UNICAMP

Universidade Estadual de Campinas

Instituto de Matemática, Estatística e
Computação Científica — IMECC

Diagnóstico Físico do Resíduo em Redes Neurais Informadas pela Física (PINNs)

Uma Análise via Teoria da Equação Modificada

Aluno:

Guilherme Medeiros

RA: 256774

Disciplina:

MS901 — Tópicos Especiais de
Matemática Aplicada (Turma A)

Professores:

Prof. Eduardo Abreu

Prof. João Florindo

IMECC — Unicamp

1.^o Semestre de 2026

Sumário

1	Introdução	2
2	Motivação e Contexto	3
2.1	O Problema da Análise do Erro em PINNs	3
2.2	A Teoria da Equação Modificada como Ferramenta de Auditoria	3
2.3	Por que isso importa?	4
3	Estrutura do Projeto	4
3.1	Modelo I: Equação de Advecção Linear	4
3.2	Modelo II: Equação de Burgers Invíscida	5
3.3	Metodologia de Diagnóstico	5
4	Perguntas de Pesquisa	6

1. Introdução

A simulação computacional de fenômenos físicos governados por equações diferenciais parciais (EDPs) é um dos pilares da Matemática Aplicada moderna. Durante décadas, esse campo foi dominado por métodos clássicos de discretização — diferenças finitas, volumes finitos e elementos finitos — cujas propriedades de estabilidade, consistência e convergência são rigorosamente estabelecidas pela Análise Numérica.

Nas últimas décadas, o advento do aprendizado profundo trouxe uma nova família de métodos: as **Physics-Informed Neural Networks** (PINNs) [1]. Em vez de discretizar o domínio em malhas, as PINNs parametrizam a solução $u(x, t)$ como uma rede neural $\hat{u}_\theta(x, t; \theta)$ e incorporam a EDP diretamente na função de custo (*loss*):

$$\mathcal{L}(\theta) = \underbrace{\frac{1}{N_f} \sum_{i=1}^{N_f} |f(x_f^i, t_f^i; \theta)|^2}_{\text{loss física (resíduo EDP)}} + \lambda \underbrace{\frac{1}{N_u} \sum_{j=1}^{N_u} |\hat{u}_\theta(x_u^j, t_u^j) - u^j|^2}_{\text{loss de dados (CI/CC)}}, \quad (1)$$

onde $f := \partial_t u + \mathcal{N}[u]$ é o resíduo do operador diferencial e $\{x_u^j, t_u^j, u^j\}$ são os pontos de condição inicial e de contorno.

A beleza da abordagem está na sua generalidade: não há malha, não há restrições de dimensionalidade impostas pela discretização, e a rede pode, em princípio, aproximar soluções de problemas de alta dimensão onde os métodos clássicos sucumbem à *maldição da dimensionalidade*.

Entretanto, essa flexibilidade vem com um custo epistemológico relevante: ao minimizar $\mathcal{L}(\theta)$, raramente se atinge o resíduo nulo. Isso significa que a rede não está resolvendo a EDP original, mas sim uma **equação perturbada**:

$$\partial_t \hat{u}_\theta + \mathcal{N}[\hat{u}_\theta] = r(x, t), \quad (2)$$

onde $r(x, t)$ é o campo de resíduo da rede treinada. A pergunta central deste trabalho é precisamente:

Perguntas de Pesquisa

O que o resíduo residual $r(x, t)$ de uma PINN está fazendo com a física que ela deveria resolver? Ele age como uma perturbação difusiva, introduzindo viscosidade artificial? Ou age como uma perturbação dispersiva, gerando oscilações espúrias? E como a escolha da arquitetura da rede influencia essa perturbação?

A resposta a essas perguntas é fornecida pela **Teoria da Equação Modificada**, um instrumento clássico de Análise Numérica que, neste trabalho, é transplantado para

o contexto das redes neurais.

2. Motivação e Contexto

2.1. O Problema da Análise do Erro em PINNs

A convergência dos métodos numéricos clássicos é garantida pelo Teorema de Lax-Richtmyer: um método consistente e estável é necessariamente convergente. Esse teorema conecta três conceitos bem definidos — consistência (o esquema aproxima bem a EDP), estabilidade (o erro não cresce sem controle) e convergência (a solução numérica se aproxima da solução exata quando o passo tende a zero).

Para PINNs, esse quadro é mais nebuloso. A loss $\mathcal{L}(\theta)$ mede o resíduo em pontos de colocação, mas não há uma teoria geral que conecte o valor da loss à distância $\|\hat{u}_\theta - u_{\text{exata}}\|$ de forma tão precisa quanto nos métodos clássicos. Pior: uma loss pequena pode coexistir com erros grandes em regiões do domínio mal cobertas pelos pontos de colocação.

2.2. A Teoria da Equação Modificada como Ferramenta de Auditoria

A Teoria da Equação Modificada, introduzida por Hirt [2] no contexto de diferenças finitas, oferece uma resposta elegante a uma pergunta análoga: *qual equação um esquema numérico está efetivamente resolvendo?*

A ideia central é expandir os termos do esquema numérico em série de Taylor ao redor do ponto exato e identificar os termos de erro dominantes. Para o esquema de Lax-Friedrichs aplicado à advecção linear $u_t + a u_x = 0$, por exemplo, a equação modificada é:

$$u_t + a u_x = \underbrace{\nu_{\text{LF}} u_{xx}}_{\text{difusão artificial}} + \mathcal{O}(\Delta x^2), \quad \nu_{\text{LF}} = \frac{\Delta x}{2}(1 - \text{CFL}), \quad (3)$$

revelando que o esquema é difusivo de primeira ordem.

A proposição central deste trabalho é a seguinte:

Equação Modificada Neural

Dado uma PINN treinada $\hat{u}_\theta$ com resíduo $r(x, t) \neq 0$, definimos a **equação modificada neural** como

$$\partial_t \hat{u}_\theta + \mathcal{N}[\hat{u}_\theta] = \nu_{\text{num}} \partial_{xx} \hat{u}_\theta + \beta_{\text{num}} \partial_{xxx} \hat{u}_\theta + \mathcal{O}(\text{termos de ordem superior}), \quad (4)$$

onde $\nu_{\text{num}} \geq 0$ é a **viscosidade numérica neural** e β_{num} é o coeficiente de **dispersão numérica neural**. O resíduo age como uma perturbação da EDP original: se ν_{num} domina, a rede suaviza a solução (difusão); se β_{num} domina, a rede introduz oscilações (dispersão).

2.3. Por que isso importa?

O diagnóstico da equação modificada neural tem implicações práticas diretas:

1. **Estabilidade física:** um $\nu_{\text{num}} > 0$ grande indica que a rede está “amortecendo” a solução, potencialmente suavizando discontinuidades como choques — exatamente o oposto do comportamento desejado em leis de conservação hiperbólicas.
2. **Escolha de arquitetura:** se ν_{num} depende da função de ativação, da profundidade ou da largura da rede, então a escolha arquitetural tem interpretação física, não apenas empírica.
3. **Conexão AN–SciML:** o mesmo coeficiente ν_{num} calculado para métodos clássicos (Equação 3) pode ser calculado para PINNs, permitindo uma comparação direta e fundamentada.

3. Estrutura do Projeto

O projeto está organizado em torno de dois modelos-problema, de complexidade crescente, aplicados à mesma metodologia de diagnóstico.

3.1. Modelo I: Equação de Advecção Linear

O ponto de partida é a equação de advecção linear,

$$u_t + a u_x = 0, \quad x \in [x_{\min}, x_{\max}], \quad t \in [0, T], \quad (5)$$

com velocidade de advecção constante $a > 0$ e condição inicial $u(x, 0) = u_0(x)$.

Esta equação tem solução exata via método das características, $u(x, t) = u_0(x - at)$, o que permite medir o erro exato da PINN e calibrar o diagnóstico. Adicionalmente, a

estimativa de energia de Gronwall,

$$\int u^2(x, t) dx \leq e^{\|a\|_{C^1} \cdot t} \int u_0^2(x) dx, \quad (6)$$

fornece uma cota física que a solução da PINN deve respeitar.

3.2. Modelo II: Equação de Burgers Invíscida

O segundo modelo é a equação de Burgers invíscida,

$$u_t + \left(\frac{u^2}{2} \right)_x = 0, \quad x \in \Omega, \quad t \in [0, T], \quad (7)$$

com dados iniciais de Riemann (choque ou rarefação). Este é o teste de fogo: a solução desenvolve uma descontinuidade (choque) em tempo finito, e o comportamento do resíduo próximo ao choque revela se a PINN introduz viscosidade artificial suficiente para estabilizar a solução ou se gera oscilações dispersivas.

A solução exata do problema de Riemann para choque é $u(x, t) = u_L \cdot \mathbf{1}_{x < st} + u_R \cdot \mathbf{1}_{x \geq st}$, onde $s = (u_L + u_R)/2$ é a velocidade do choque dada pela condição de Rankine-Hugoniot.

3.3. Metodologia de Diagnóstico

Para ambos os modelos, o diagnóstico segue o mesmo protocolo:

1. **Treinamento da PINN** com a arquitetura em análise (minimização da Equação 1).
2. **Cálculo do campo de resíduo** $r(x, t_0)$ em instantes fixados $t_0 \in (0, T]$, usando diferenciação automática.
3. **Análise espectral via FFT**: transformada de Fourier discreta do resíduo $\hat{R}(k)$ e da solução $\hat{U}(k)$.
4. **Estimativa de ν_{num}** : se o resíduo é dominado por difusão, então $\hat{R}(k) \approx \nu_{\text{num}} k^2 \hat{U}(k)$, logo

$$\nu_{\text{num}} \approx \text{mediana} \left\{ \frac{|\hat{R}(k)|}{k^2 |\hat{U}(k)|} \right\}_{k>0}. \quad (8)$$

5. **Classificação**: comparação da energia espectral em baixas e altas frequências para determinar se o erro é predominantemente difusivo ou dispersivo.

4. Perguntas de Pesquisa

O projeto busca responder às seguintes perguntas, em ordem crescente de profundidade:

1. **[Diagnóstico base]** Para uma PINN treinada na equação de advecção linear com condição inicial suave ($u_0 = \sin(\pi x)$), o resíduo residual é classificado como difusivo ou dispersivo? Qual é a ordem de grandeza de ν_{num} ?
2. **[Sensibilidade arquitetural]** Como ν_{num} varia com a escolha de: (a) função de ativação (`tanh`, `sin`, `relu`, `swish`); (b) número de neurônios por camada; (c) profundidade da rede; (d) número de pontos de colocação N_f ?
3. **[Comparação AN–SciML]** O ν_{num} estimado para a PINN é comparável ao ν_{LF} do método de Lax-Friedrichs com o mesmo custo computacional? A PINN consegue atingir viscosidade artificial menor do que métodos clássicos de primeira ordem?
4. **[Robustez em dados descontínuos]** O diagnóstico se mantém coerente quando a condição inicial é descontínua (dado de Riemann)? O resíduo se concentra na região do choque? O comportamento muda para a equação de Burgers?
5. **[Relação loss–erro físico]** Existe correlação entre o valor escalar da loss $\mathcal{L}(\theta)$ e a viscosidade numérica ν_{num} ? Uma loss menor implica necessariamente menor perturbação da física?

Referências

- [1] Maziar Raissi, Paris Perdikaris e George Em Karniadakis. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. Em: *Journal of Computational Physics* 378 (2019), pp. 686–707. DOI: [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045).
- [2] C. W. Hirt. “Heuristic stability theory for finite-difference equations”. Em: *Journal of Computational Physics* 2.4 (1968), pp. 339–355. DOI: [10.1016/0021-9991\(68\)90041-7](https://doi.org/10.1016/0021-9991(68)90041-7).