

Roteiro de Prática Docente Integrada

Integração de Machine Learning e Análise Numérica para EDPs

IMECC - Universidade de Campinas (Unicamp)

Disciplina: MS901 - Tópicos Especiais de Matemática Aplicada (no contexto de integração com a Pós - Tópicos em Aprendizagem de Matemática Aplicada e Computacional - MT861)

Responsáveis pela Turma A de MS901 (1s/2026): Prof. Eduardo Abreu e Prof. João Florindo

Visão Geral do Projeto Pedagógico

A disciplina propõe uma ruptura com o ensino isolado de métodos computacionais. A prática centra-se na **Scientific Machine Learning (SciML)**, onde a Inteligência Artificial (IA) é auditada pelo rigor da Análise Numérica. O foco é a integração de modelos de equações diferenciais parciais (EDPs) com algoritmos de aprendizado de máquina, fundamentados em resultados de estabilidade e consistência.

Público-Alvo

Esta disciplina foi concebida prioritariamente para estudantes do Bacharelado em Matemática Aplicada e Computacional, atendendo tipicamente aqueles que já concluíram o ciclo básico (o “Cursão”). No entanto, as portas estão abertas a todos os alunos da Unicamp que possuam afinidade com a temática e o rigor da ementa.

Transdisciplinaridade e Superação de Fronteiras

O objetivo central é proporcionar uma imersão que transcende a formação técnica tradicional, oferecendo uma experiência transdisciplinar robusta. Buscamos conectar a sofisticação teórica da Análise Numérica (AN) às fronteiras tecnológicas do Machine Learning Científico (SciML), focando na resolução de modelos complexos de Equações Diferenciais Parciais (lineares e não lineares) motivados por desafios contemporâneos e multidimensionais do mundo real.

Esta integração estratégica entre AN e SciML não se restringe a um domínio isolado; sua arquitetura metodológica possui uma natureza transversal, podendo ser replicada com sucesso em qualquer área que utilize a modelagem de sistemas complexos. Isso inclui campos vitais como a Física, a Química e as diversas Engenharias, onde a fusão entre o rigor dos primeiros princípios e a flexibilidade dos dados permite capturar fenômenos de alta complexidade com precisão e eficiência computacional sem precedentes.

A Pesquisa e a Autonomia como Eixos de Formação

Mais do que uma série de exposições passivas, estes seminários consolidam a pesquisa como método fundamental de formação. O norte da iniciativa é promover a transição do saber estático e isolado para uma prática científica integrada, na qual o estudante deixa de ser apenas um espectador para se tornar um sujeito ativo, aprendendo a investigar e a construir conhecimento de forma cooperativa.

Para que essa evolução ocorra, a experiência exige um alto grau de independência e autonomia acadêmica: embora não existam travas formais, o sucesso do participante depende de um perfil proativo e de um compromisso rigoroso com o estudo da literatura de vanguarda. Essa postura é essencial para que o aluno domine a complexa interação entre teoria e aplicação, desenvolvendo as competências críticas necessárias para enfrentar desafios contemporâneos e construir soluções inovadoras em suas futuras carreiras.

Perfil Esperado e Requisitos

Embora não existam pré-requisitos formais (travas de sistema), o sucesso no curso está atrelado à maturidade acadêmica e ao engajamento com os seguintes pilares:

- **Independência Acadêmica:** Espera-se que o aluno tenha proatividade para o estudo ativo da literatura recomendada, que servirá como base fundamental das discussões.
- **Interação Teórico-Prática:** O conteúdo explora uma interface avançada entre Análise Numérica e Machine Learning, focada na resolução de Equações Diferenciais Parciais (EDPs) lineares e não lineares.
- **Foco em Problemas Reais:** A disciplina utiliza modelos complexos motivados por desafios contemporâneos, exigindo capacidade de abstração e aplicação técnica simultâneas.

Estrutura Didática: Disciplina Espelho

A disciplina foi estruturada sob o modelo de “Disciplina Espelho”. Isso significa que as versões de graduação e pós-graduação tramitam de forma integrada, facilitando o aproveitamento de créditos e promovendo uma rica troca de experiências entre diferentes níveis de formação acadêmica.

Pilar I: A IA sob a Lente da Análise Numérica

1.1 Investigação de Erros e Estabilidade

Os alunos tratam o *Deep Learning* como um problema de aproximação funcional, onde a minimização da *loss* deve ser acompanhada pela análise do resíduo da EDP.

1.2 Fundamentação de Algoritmos de Aprendizagem

Decomposição de otimizadores (Adam, SGD) como sistemas dinâmicos discretos, relacionando a convergência da rede com passos de tempo em métodos de integração.

1.3 Conexão: Loss de Deep Learning e Equação Modificada

Este item representa o núcleo da interpretação física do erro numérico em Redes Neurais Informadas pela Física (PINNs).

- **O Resíduo como Perturbação:** A análise de resíduos na *loss* da PINN é interpretada através da **Teoria da Equação Modificada**. Quando a rede não atinge o resíduo zero, a solução aproximada $\hat{u}$ satisfaz, de fato, uma equação do tipo $\mathcal{L}(\hat{u}) = \epsilon$, onde ϵ é o erro da **loss**.

- **Significado Físico do Erro:** O erro ϵ é decomposto para identificar fenômenos de **Difusão Numérica** (erros de ordem par) ou **Dispersão Numérica** (erros de ordem ímpar).
- **Exemplo Prático:** Na equação de advecção linear $u_t + au_x = 0$, uma *loss* residual não nula pode manifestar-se como um termo de viscosidade artificial $\nu_{num}u_{xx}$. O aluno deve diagnosticar se a "falha" da rede em aprender o perfil exato é uma dissipação espúria ou uma oscilação dispersiva inerente à arquitetura.
- **Aplicação em PINNs:** Investigar como a escolha da função de ativação e da profundidade da rede atua como um regulador da "Equação Modificada Neural".

Pilar II: Superação da Lacuna de Abstração

2.1 Desafios de Alta Dimensão

Propõe-se a utilização de PINNs como uma estratégia para contornar as limitações intrínsecas aos métodos clássicos de discretização. Em cenários onde a geração de malhas e o processamento de grandes volumes de dados sofrem com a maldição da dimensionalidade, as PINNs emergem como um paradigma meshless essencial. Esta abordagem é particularmente crítica em desafios de engenharia multidimensional, transformando problemas anteriormente intratáveis em soluções viáveis por meio da integração entre leis físicas e redes neurais.

2.2 Tratamento de Incerteza e Dados Massivos

Discernir entre erro numérico (discretização) e incerteza epistêmica (dados), integrando a precisão estatística ao rigor analítico. Note-se ainda que o conceito de “IA auditada pelo rigor da Análise Numérica” permite que outras disciplinas científicas verifiquem se modelos de aprendizado de máquina respeitam leis físicas e resultados de estabilidade.

Diferencial de Inovação

A disciplina adota a metodologia de "**Diagnóstico Físico do Resíduo**": O aluno deve provar se o erro residual da sua PINN comporta-se como um termo difusivo ou dispersivo, conectando o valor da *loss* à estabilidade do modelo físico original.

Pilar III: Metodologia e Ciclo de Aprendizagem

3.1 A Tríade Teórica-Computacional

1. **Teoria Sólida:** Revisão de convergência e análise de Hirt para equações modificadas.
2. **Aplicação Real:** Implementação em áreas como bioinformática e mecânica dos fluidos.
3. **Cálculo de Alto Desempenho (HPC):** Uso de GPUs para acelerar o treinamento e a análise de sensibilidade do resíduo.

Sistema de Avaliação Integrado

Fase 1: Projeto de Implementação e Relatório

Relatório em LaTeX focado na **Análise de Equação Modificada** da PINN implementada, seguindo padrões de revistas de alto impacto.

Fase 2: Seminário e Defesa Crítica

Apresentação focada na interpretação física: "O que a *loss* da minha rede está dizendo sobre a física que ela não conseguiu capturar?"

Do Desenvolvimento à Comunicação

O eixo prático da experiência consolida-se na síntese entre o Projeto de Implementação e o correspondente Relatório Técnico, onde o estudante materializa a resolução de modelos complexos por meio de métodos numéricos e algoritmos de Machine Learning.

Complementando essa etapa, o processo culmina no Seminário e na Defesa Crítica, momentos em que o aluno é desafiado a exercitar a alteridade e o rigor acadêmico. Mais do que uma apresentação, a defesa é o espaço para a validação do conhecimento construído em cooperação, exigindo clareza na exposição de ideias e capacidade de sustentar escolhas metodológicas diante de problemas reais. Essa jornada assegura que a formação vá além do código, desenvolvendo a retórica científica e a postura crítica indispensáveis ao pesquisador de alto nível.

Sugestões de Tópicos de Seminários “Do Desenvolvimento à Comunicação”:

Seminário 1: A Matemática e a Física do erro na Inteligência Artificial (IA)

Objetivo: Ensinar como interpretar a *loss* de PINNs através de equações modificadas e difusão/dispersão numérica.

Seminário 2: Matemática Aplicada e Científica

Objetivo: Debater a atualização de ementas tradicionais para incluir SciML sem perder a profundidade analítica.

Seminário 3: Do Teorema ao Algoritmo

Objetivo: Mostrar a AN como ponte para inovação tecnológica em indústrias emergentes: a Matemática Aplicada como ponte de sinergia entre Academia e a Sociedade.

Referências

- [1] Juan Diego Toscano, Vivek Oommen, Alan John Varghese, Zongren Zou, Nazanin Ahmadi Daryakenari, Chenxi Wu, George Em Karniadakis (2025). *From PINNs to*

- PIKANs: recent advances in physics-informed machine learning*. Mach. Learn. Comput. Sci. Eng 1, 15. <https://doi.org/10.1007/s44379-025-00015-1>
- [2] E. Abreu, J. Florindo, W. Lambert (2024). *A PDE-informed and Physics-informed neural network for learning weak solutions in two-dimensional conservation laws*. 9th European Congress on Computational Methods in Applied Sciences and Engineering.
 - [3] J. B. Florindo and E. Abreu (2024). *A pseudo-parabolic diffusion model to enhance deep neural texture features*. Multimedia Tools and Applications, 83(4), 11507-11528.
 - [4] S. J. Prince (2023). *Understanding deep learning*. MIT Press.
 - [5] J. Vieira, E. Abreu, and J. B. Florindo (2023). *Texture image classification based on a pseudo-parabolic diffusion model*. Multimedia Tools and Applications, 82(3), 3581-3604.
 - [6] R. A. F. Carniello, J. B. Florindo and E. Abreu (2022). *A PINN computational study for a scalar 2d inviscid burgers model with riemann data*. 8th European Congress on Computational Methods in Applied Sciences and Engineering.
 - [7] S. Kollmannsberger, D. D'Angella, M. Jokeit, and L. Herrmann (2021). *Deep learning in computational mechanics* (pp. 55-84). Springer International Publishing.
 - [8] J. B. Florindo and E. Abreu (2021). *An application of a pseudo-parabolic modeling to texture image recognition*. International Conference on Computational Science (pp. 386-397). Cham: Springer International Publishing.
 - [9] E. Abreu and J. B. Florindo (2021). *A study on a feedforward neural network to solve partial differential equations in hyperbolic-transport problems*. International Conference on Computational Science (pp. 398-411). Cham: Springer International Publishing.
 - [10] M. Raissi, P. Perdikaris, and G. E. Karniadakis (2019). *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 378, 686-707.
 - [11] A. Bartel and M. Günther (2018). *PDAEs in Refined Electrical Network Modeling*. SIAM Rev., 60(1), 56-91.
 - [12] Mayer Humi (2017). *Introduction to mathematical modeling*. Taylor & Francis Group.
 - [13] Ka-Kit Tung (2007). *Topics in mathematical modeling*. Princeton University Press.
 - [14] Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). *Scientific machine learning through physics-informed neural networks: Where we are and what's next*. Journal of Scientific Computing, 92(3), 88.